

目录

1 BME-RAMP 贝叶斯最大熵融合方法数学原理 1

1.1 目录 1

1.2 1 概述 2

1.3 2 数据变换 2

1.4 3 BME 估计方法论 3

1.5 4 RAMP 软数据构建 5

1.6 5 Offset 偏移量分析 6

1.7 6 时空协方差模型 7

1.8 7 空间预测 8

1.9 8 完整算法伪代码 9

1.10 9 与其他方法的对比 10

1.11 10 超参数默认值 12

1.12 参考文献 13

1 BME-RAMP 贝叶斯最大熵融合方法数学原理

基于 Xu et al. (2016) Bayesian Maximum Entropy + RAMP 区域化模型性能评估框架 2026-06-08

1.1 目录

- 1. 概述
- 2. 数据变换
- 3. BME 估计方法论
- 4. RAMP 软数据构建
- 5. Offset 偏移量分析
- 6. 时空协方差模型
- 7. 空间预测
- 8. 完整算法伪代码
- 9. 与其他方法的对比
- 10. 超参数默认值
- 11. 参考文献

1.2 1 概述

BME-RAMP (Bayesian Maximum Entropy with Regionalized Air Quality Model Performance) 是一种现代化的时空数据融合方法, 将化学传输模型 (CTM/CAMx) 的粗分辨率预测与稀疏的地面监测站点观测数据进行融合, 生成高分辨率的臭氧 (O_3) 或 $PM_{2.5}$ 浓度估计。

该方法由 Xu et al. (2016) 在 *Environmental Science & Technology* 上发表, 是对 de Nazelle et al. (2010) BME 融合框架的重要扩展, 核心改进包括:

1. **BME** 框架: 基于最大熵原理和贝叶斯条件化, 能够融合非线性、非高斯知识源
2. **RAMP** 方法: 区域化空气质量模型性能评估, 首次考虑 CTM 模型性能的时空变异性
3. 非参数软数据: 不预设观测-预测之间的参数化关系 (如线性、同方差), 完全保留非线性和异方差性
4. **Offset** 变换: 通过核平滑估计确定性趋势, 将非平稳场转化为平稳随机场
5. 解析不确定性: 直接给出预测值的后验均值和方差

方法来源:

- **BME** 理论: Christakos (1990, 2000) 现代地统计学的“知识处理”框架
- **CAMP** 前身: de Nazelle et al. (2010) 恒定模型性能假设 (仅适用于小区域、短时段)
- **RAMP** 创新: Xu et al. (2016) 将 CAMP 扩展为 RAMP, 允许模型性能在空间和时间上变化

应用场景:

- 美国大陆尺度 (continental U.S.) 臭氧日浓度估计
- 两种时间指标: DM8A (日最大 8 小时平均) 和 D24A (日 24 小时平均)
- 可扩展至 $PM_{2.5}$ 等其他标准空气污染物

1.3 2 数据变换

1.3.1 2.1 前向 Offset 变换

设 $Z(p) = Z(s, t)$ 为表示日臭氧浓度的时空随机场 (S/TRF), 其中 $p = (s, t)$ 为时空坐标。

将 $Z(p)$ 分解为确定性趋势 (offset) 与平稳随机场之和:

$$Z(p) = X(p) + o_Z(p) \quad (1)$$

其中: - $o_Z(p)$: offset 偏移量, 是时空坐标 p 的确定性函数, 可无误差计算 - $X(p)$: 平稳/均匀时空随机场, 表示去除 offset 后的变率和不确定性

对观测数据 z_o 在位置 p_o 进行变换：

$$x_o = z_o - o_Z(p_o) \quad (2)$$

1.3.2 2.2 Offset 的计算

Offset $o_Z(p_i)$ 通过对周围观测数据的指数核平滑计算：

$$o_Z(p_i) = \frac{\sum_{j=1}^N w_j z_j}{\sum_{j=1}^N w_j} \quad (3)$$

其中 z_j 为 p_i 邻域内的观测值，核平滑权重为：

$$w_j = \exp\left(-\frac{\|\mathbf{s}_i - \mathbf{s}_j\|}{a_r}\right) \cdot \exp\left(-\frac{|t_i - t_j|}{a_t}\right) \quad (4)$$

- a_r : 空间平滑范围 (km)
- a_t : 时间平滑范围 (day)

最优 **offset** 选择: $a_r = 50$ km, $a_t = 10$ 天, 在低方差 (最小化估计误差) 和高自相关 (邻域信息充分) 之间取得平衡。

1.3.3 2.3 反变换

预测完成后, 从 offset-removed 尺度回到原始浓度尺度：

$$\hat{z}_k = \hat{x}_k + o_Z(p_k) \quad (5)$$

其中 $\hat{x}_k$ 为 BME 对 $X(p_k)$ 的估计值。

1.4 3 BME 估计方法论

1.4.1 3.1 知识库定义

BME 框架将知识分为两类：

G-KB (General Knowledge Base, 一般知识库):

$$G = \{m_X(p), c_X(p, p')\}$$

- $m_X(p) = E[X]$: 均值函数, 描述一致性趋势
- $c_X(p, p') = E[(X(p) - m_X(p))(X(p') - m_X(p'))]$: 协方差函数, 描述时空依赖结构

S-KB (Site-specific Knowledge Base, 站点知识库):

$$S = \{x_o, f_S(\mathbf{x}_m)\}$$

- x_o : hard data (硬数据), 观测站点处的精确值
- $f_S(\mathbf{x}_m)$: soft data (软数据), CTM 预测点处的概率密度函数

1.4.2 3.2 BME 三步骤

步骤 1 一先验 PDF: 利用最大熵原理处理 G-KB, 得到先验概率密度函数 f_G 。当 G-KB 仅包含均值和协方差时, f_G 为高斯 PDF。

步骤 2 一后验 PDF: 利用贝叶斯条件化规则整合 S-KB:

$$f_K(x_k) = A^{-1} \int f_S(\mathbf{x}_m) \cdot f_G(\mathbf{x}_{map}) d\mathbf{x}_m \quad (6)$$

其中 $\mathbf{x}_{map} = (x_k, \mathbf{x}_o, \mathbf{x}_m)$ 为映射点的全体值, A 为归一化常数。

步骤 3 一估计: 基于 BME 后验 PDF 计算时空估计值 (如后验均值、后验方差)。

1.4.3 3.3 硬数据与软数据

硬数据: 监测站点的观测值 x_o , 视为无误差代理 (hard data, error-free proxy)。

软数据: CTM 计算节点处的 offset-removed 值 x_m , 以 PDF $f_S(\mathbf{x}_m)$ 描述其不确定性:

$$f_S(\mathbf{x}_m) = \prod_{i=1}^{n_m} f(x_i | \tilde{x}_i, p_i) \quad (7)$$

其中 $\tilde{x}_i$ 为 offset-removed CTM 预测值, $f(x_i | \tilde{x}_i, p_i)$ 刻画 CTM 在时空点 p_i 处的预测性能。

1.4.4 3.4 CAMP vs RAMP 的关键区别

CAMP (Constant Air quality Model Performance): 参数 λ_1, λ_2 仅随 CTM 预测值变化, 不随空间/时间变化:

$$f(z_i|\tilde{z}_i) = \Phi(z_i; \lambda_1(\tilde{z}_i), \lambda_2(\tilde{z}_i)) \quad (8)$$

RAMP (Regionalized Air quality Model Performance): 参数 λ_1, λ_2 同时随 CTM 预测值和时空坐标变化:

$$f(z_i|\tilde{z}_i, p_i) = \Phi(z_i; \lambda_1(\tilde{z}_i, p_i), \lambda_2(\tilde{z}_i, p_i)) \quad (9)$$

其中 Φ 为零以下截断的正态分布: - $\lambda_1(\tilde{z}_i, p_i)$: 期望值 (bias-corrected 预测值) - $\lambda_2(\tilde{z}_i, p_i)$: 方差 (bias-corrected 预测的不确定性)

1.5 4 RAMP 软数据构建

1.5.1 4.1 第一阶段: 站点级分层统计

对每个监测站点 s_n 和时间 t :

配对池化: 收集时间窗口 $\Delta T = 120$ 天内所有观测-预测对 $(z_j, \tilde{z}_j)$ 。

十分层: 按预测值 $\tilde{z}_j$ 排序, 等分为 10 个分位区间 (bins)。

逐层统计: 对第 b 层 (预测均值为 $\tilde{z}_b$), 计算:

$$\hat{\lambda}_1(\tilde{z}_b, s_n, t) = \frac{1}{n_0(\tilde{z}_b, s_n, t)} \sum_{j: \tilde{z}_j \in \text{bin}_b} z_j(s_n, t) \quad (10)$$

$$\hat{\lambda}_2(\tilde{z}_b, s_n, t) = \frac{1}{n_0(\tilde{z}_b, s_n, t)} \sum_{j: \tilde{z}_j \in \text{bin}_b} (z_j(s_n, t) - \hat{\lambda}_1(\tilde{z}_b, s_n, t))^2 \quad (11)$$

其中 $n_0(\tilde{z}_b, s_n, t)$ 为第 b 层中的配对数量。

$\Delta T = 120$ 天的选择理由: 在数据充足性 (大窗口样本多) 和季节特异性 (小窗口更能反映当前季节的模型性能特征) 之间取得平衡。

1.5.2 4.2 第二阶段: 空间插值到 CTM 网格

对每个 CTM 计算节点 $p_i = (s_i, t_i)$:

步骤 **A** — 预测值维度插值: 对每个站点 s_n , 在 10 个 bin 点之间进行线性插值/外推, 获得连续预测值 $\tilde{z}_i$ 对应的期望和方差:

$$\hat{\lambda}_1(\tilde{z}_i, s_n, t_i), \quad \hat{\lambda}_2(\tilde{z}_i, s_n, t_i)$$

步骤 **B** — 空间维度插值：将各站点的结果空间插值到 CTM 节点：

$$\hat{\lambda}_k(\tilde{z}_i, p_i) = \frac{\sum_{n=1}^N w(s_i, s_n) \cdot \hat{\lambda}_k(\tilde{z}_i, s_n, t_i)}{\sum_{n=1}^N w(s_i, s_n)}, \quad k = 1, 2 \quad (12)$$

空间权重为反距离：

$$w(s_i, s_n) = \frac{1}{\text{dist}(s_i, s_n)} \quad (13)$$

其中 $n = 1, \dots, N$ 为距离 s_i 最近的 N 个监测站点。

物理含义：

- $\tilde{z}_i - \hat{\lambda}_1(\tilde{z}_i, p_i)$: CTM 在 p_i 处的系统偏差 (bias)
- $\hat{\lambda}_2(\tilde{z}_i, p_i)$: CTM 在 p_i 处的不精确度 (imprecision/variance)

非参数优势：RAMP 不预设 z 与 $\tilde{z}$ 之间的任何函数关系（不假设线性、不假设同方差），地理和时间上的非线性、非齐性关系被自动捕获。

注意：RAMP 输出的 $\hat{\lambda}_1, \hat{\lambda}_2$ 定义于原始浓度空间。在实际 BME 融合中，需通过 offset 关系 $x = z - o_Z(p)$ 将软数据变换到 offset-removed 空间： $f(x_i | \tilde{x}_i, p_i) = \Phi(x_i; \hat{\lambda}_1 - o_Z(p_i), \hat{\lambda}_2)$ 。

1.6 5 Offset 偏移量分析

1.6.1 5.1 定义与目的

Offset 变换将原始臭氧数据 $Z(p)$ 分解为平滑趋势 $o_Z(p)$ 和平稳残差 $X(p)$ 。其目的是：

1. 去除大尺度时空趋势，使 $X(p)$ 满足平稳性假设
2. 降低变换后数据的方差，最小化估计误差
3. 保留足够的时空自相关，确保邻域信息充分

1.6.2 5.2 核平滑参数

基于方差-自相关平衡准则选择最优参数：

参数	符号	最优值	说明
空间范围	a_r	50 km	指数核空间平滑范围
时间范围	a_t	10 day	指数核时间平滑范围

1.6.3 5.3 与均值函数的关系

在 G-KB 中, $m_X(p)$ 为 offset-removed 数据 x_o 的均值。理想情况下, $m_X(p) \approx 0$ ($X(p)$ 为零均值平稳场)。

1.7 6 时空协方差模型

1.7.1 6.1 实验协方差计算

从变换后的观测数据 $x_o = z_o - o_Z(p_o)$ 计算实验协方差。

对空间滞后 r 和时间滞后 τ :

$$\hat{c}_X(r, \tau) = \frac{1}{N(r, \tau)} \sum_{j=1}^{N(r, \tau)} (x_{\text{head},j} - m_X)(x_{\text{tail},j} - m_X) \quad (14)$$

其中 $N(r, \tau)$ 为空间滞后 r 、时间滞后 τ 处的数据对数量, m_X 为 x_o 的均值。

实际中分别计算和绘制 $\hat{c}_X(r, 0)$ (空间协方差) 和 $\hat{c}_X(0, \tau)$ (时间协方差)。

1.7.2 6.2 三结构指数协方差模型

采用三结构 (3-structured) 指数协方差模型:

$$c_X(r, \tau) = C_0 \cdot \left[\exp\left(-\frac{3r}{a_{r1}}\right) \cdot \exp\left(-\frac{3\tau}{a_{t1}}\right) + (1 - \alpha) \cdot \exp\left(-\frac{3r}{a_{r2}}\right) \cdot \exp\left(-\frac{3\tau}{a_{t2}}\right) + \beta \cdot \exp\left(-\frac{3r}{a_{r3}}\right) \cdot \exp\left(-\frac{3\tau}{a_{t3}}\right) \right]$$

物理解释: 三结构分别对应小尺度 (短程相关性)、中尺度和大尺度 (长程相关性) 的时空变异成分。

1.7.3 6.3 待估协方差参数

参数	符号	说明
基础方差	C_0	第一结构的偏基台值
结构权重	α, β	第二、三结构相对于第一结构的方差比例
空间范围 1/2/3	a_{r1}, a_{r2}, a_{r3}	不同尺度的空间相关范围
时间范围 1/2/3	a_{t1}, a_{t2}, a_{t3}	不同尺度的时间相关范围
总基台值	$C_0 \cdot (2 - \alpha + \beta)$	总方差 (total sill)

1.8 7 空间预测

1.8.1 7.1 BME 后验估计

给定硬数据 x_o 和软数据 PDF $f_S(x_m)$, BME 后验 PDF $f_K(x_k)$ 在估计点 p_k 处的值由式 (6) 给出。

在实际实现中 (G-KB 为高斯型), BME 简化为带有软数据的克里金扩展。

1.8.2 7.2 估计值计算

后验均值 (点估计):

$$\hat{x}_k = E_{f_K}[X(p_k)] = \int x_k \cdot f_K(x_k) dx_k \quad (16)$$

后验方差 (不确定性):

$$\hat{\sigma}_k^2 = \text{Var}_{f_K}[X(p_k)] = \int (x_k - \hat{x}_k)^2 \cdot f_K(x_k) dx_k \quad (17)$$

1.8.3 7.3 最终预测

将 offset 加回, 使用式 (5) 反变换得到最终预测值 $\hat{z}_k$, 同时输出后验标准差 $\sqrt{\hat{\sigma}_k^2}$ 作为不确定性度量。

1.8.4 7.4 三种估计场景

场景	数据源	特点
OBS	仅观测硬数据	克里金的线性限制情况 (BME 的退化形式)
CAMP	观测 + CTM (恒定性能软数据)	de Nazelle et al. 的原始方法
RAMP	观测 + CTM (区域化性能软数据)	Xu et al. 的改进方法, 本文核心

1.8.5 7.5 验证方法

使用留一交叉验证 (noncollocated validation):

- 对于每个观测点 p_j , 排除验证半径 r_v 内的所有观测数据
- 用剩余数据重新估计 $\hat{z}_j^*(r_v)$
- 计算验证误差 $e_j^*(r_v) = \hat{z}_j^*(r_v) - z_j$

评价指标:

$$RMSE(r_v) = \sqrt{\frac{1}{n} \sum_j (e_j^*)^2} \quad (18)$$

$$R^2(r_v) = \text{Spearman's } \rho^2(\mathbf{z}^*, \mathbf{z}) \quad (19)$$

R^2 百分比改进 (相对于 OBS):

$$PC_{R^2}^{OBS \rightarrow METHOD}(r_v) = 100 \times \frac{R_{METHOD}^2(r_v) - R_{OBS}^2(r_v)}{R_{OBS}^2(r_v)} \quad (20)$$

1.9 8 完整算法伪代码

Algorithm: BME-RAMP 融合算法

Require: 监测站坐标 S , 观测值 z , CTM 网格坐标 S_{grid} , CTM 预测值 $\tilde{z}$

Ensure: 预测浓度 $\hat{z}_k$ 及后验方差 $\hat{\sigma}_k^2$

Phase 1: Offset 计算

for each 估计点 $p_k = (s_k, t_k)$ do

$o_Z(p_k) \leftarrow$ 核加权平均周围观测值 (式 3-4, $a_r=50\text{km}$, $a_t=10\text{d}$)

```

end for
for each 观测点 p_j do
  x_j <- z_j - o_Z(p_j)           {Offset 变换}
end for

```

Phase 2: 协方差建模

计算实验协方差 $\hat{c}_X(r, 0)$ 和 $\hat{c}_X(0, \tau)$ (式 14)
 拟合三结构指数协方差模型 (式 15)

Phase 3: RAMP 软数据构建

```

for each CTM 网格点 p_i = (s_i, t_i) do
  for each 最近监测站 s_n (n=1,...,N) do
    收集 |t - t_i| <= 120天的 (z_j, ~z_j) 对
    按 ~z 十分层, 计算  $\hat{\lambda}_{1}(\sim z_b, s_n, t_i)$  和  $\hat{\lambda}_{2}(\sim z_b, s_n, t_i)$  (式 10-11)
    线性插值获得  $\hat{\lambda}_{1}(\sim z_i, s_n, t_i)$  和  $\hat{\lambda}_{2}(\sim z_i, s_n, t_i)$ 
  end for
  反距离空间插值获得  $\hat{\lambda}_{1}(\sim z_i, p_i)$  和  $\hat{\lambda}_{2}(\sim z_i, p_i)$  (式 12)
  构造软数据 PDF:  $f_S(x_i) = \Phi(x_i; \hat{\lambda}_{1}, \hat{\lambda}_{2})$ 
end for

```

Phase 4: BME 估计

```

for each 估计点 p_k do
  ~x_k <- ~z_k - o_Z(p_k)           {CTM 值 offset 变换}
  计算 BME 后验 PDF f_K(x_k) (式 6)
  ~x_k <- 后验均值 (式 16)
  ~sigma2_k <- 后验方差 (式 17)
  ~z_k <- ~x_k + o_Z(p_k)           {反变换}
end for

return ~z_k, ~sigma2_k

```

1.10 9 与其他方法的对比

1.10.1 9.1 方法对比

特征	BME-RAMP	BME-CAMP	Cokriging	SVCD	Downscaler
理论框架	贝叶斯最大熵	贝叶斯最大熵	线性地质统计	空间变系数 + REML	贝叶斯 MCMC
回归模型	非参数 (无预设关系)	非参数 (无预设关系)	参数化线性	空间变系数线性	全局系数线性
异方差性	完全捕获	部分捕获	假设同方差	通过 Log 变换缓解	假设同方差
非线性	完全捕获	部分捕获	无法处理	线性 + Log 变换	线性
空间核	三结构指数	三结构指数	指数	Mat'ern ($\nu=1.5$)	指数核
参数估计	协方差拟合	协方差拟合	协方差拟合	REML (L-BFGS-B)	MCMC (2500 迭代)
数据变换	Offset 去趋势	Offset 去趋势	无	Log + 偏差修正	无变换
时间信息	利用 (时空协方差)	利用 (时空协方差)	仅空间	仅空间 (逐日独立)	仅空间 (逐日独立)
模型性能区域化	RAMP (时空变化)	CAMP (恒定)	无	无 (空间变系数间接)	无
不确定性	解析后验方差	解析后验方差	克里金方差	解析方差 + Delta Method	后验样本
训练复杂度	$O(N_{\text{pair}} + n^3)$	$O(N_{\text{pair}} + n^3)$	$O(n^3)$	$O(N_{\text{iter}} \cdot O(N_{\text{MCMC}} \cdot n^3))$	n^3
适用尺度	大陆级时空	区域级时空	区域级空间	区域级空间	区域级空间

1.10.2 9.2 优势

1. 非参数关系建模：不预设观测与 CTM 预测之间的函数形式，自动捕获非线性和异方差性，这是对 Berrocal et al. (2010)、McMillan et al. (2010) 等参数化方法的根本性超越。
2. 区域化模型性能：RAMP 方法能体现 CTM 在不同地理位置、不同季节的差异性性能（如东西海岸城市过预测偏差高、中部低），CAMP 假设恒定性能会对此过度修正。
3. 时空一体化：三维（经度 $\times$ 纬度 $\times$ 时间）而非逐日独立建模，能利用时间维度信息提高估计稳定性和连续性。
4. 硬-软数据统一框架：BME 框架天然支持将监测数据（硬数据，确定性）和 CTM 输出（软数据，概率分布）统一处理，权重由不确定性自动决定。
5. 计算效率：RAMP 基于配对数据的简单分层统计 + 确定性插值，无 MCMC 迭代、无 burn-in/thinning 问题，可在并行机上高效部署。
6. 远距离估计增强：验证半径 108 km 处 R^2 改进达 2.9%（DM8A）和 5.9%（D24A），证明该方法对远离监测站的区域尤为有效。

1.10.3 9.3 局限性

1. 协方差平稳假设： $X(p)$ 被假设为平稳/均匀 S/TRF，实际中残差可能仍含非平稳成分。
2. **Offset** 依赖核带宽：核平滑参数 (a_r, a_t) 需要针对具体研究区域调优，不同区域最优值可能不同。
3. **RAMP** 分层数固定：10 个分位区间为固定设置，数据稀疏场景可能不足或过拟合。
4. $\Delta T = 120$ 天窗口：平衡数据量与季节特异性的折中，极端季节性变化时可能不敏感。
5. 三结构协方差：模型形式（指数核、结构化）为半经验选择，需人工拟合而非自动优化。
6. 计算存储：时空协方差矩阵为 $n_{obs} \times n_{obs}$ （ n 为时空观测点数），大规模时需稀疏近似。

1.11 10 超参数默认值

参数	默认值	说明
a_r	50 km	Offset 空间核平滑范围
a_t	10 day	Offset 时间核平滑范围
ΔT	120 day	RAMP 配对池化时间窗口
N_{bins}	10	RAMP 分层数（等分位数）

参数	默认值	说明
N	最近站点数	空间插值所用近邻站点数
r_v	$\{0, 36, 72, 108\}$ km	验证半径集合
协方差类型	三结构指数	时空协方差模型类型
截断分布	零以下截断正态	软数据 PDF 形式
偏移量类型	指数核平滑	Offset 计算方法

1.12 参考文献

1. Xu, Y., Serre, M. L., Reyes, J., & Vizuite, W. (2016). Bayesian Maximum Entropy Integration of Ozone Observations and Model Predictions: A National Application. *Environmental Science & Technology*, 50(8), 4393-4400.
2. de Nazelle, A., Arunachalam, S., & Serre, M. L. (2010). Bayesian Maximum Entropy Integration of Ozone Observations and Model Predictions: An Application for Attainment Demonstration in North Carolina. *Environmental Science & Technology*, 44(15), 5707-5713.
3. Christakos, G. (2000). *Modern Spatiotemporal Geostatistics*. Oxford University Press.
4. Christakos, G. (1990). A Bayesian/maximum-entropy view to the spatial estimation problem. *Mathematical Geology*, 22(7), 763-777.
5. Serre, M. L., & Christakos, G. (1999). Modern geostatistics: computational BME analysis in the light of uncertain physical knowledge —the Equus Beds study. *Stochastic Environmental Research and Risk Assessment*, 13(1-2), 1-26.
6. Berrocal, V. J., Gelfand, A. E., & Holland, D. M. (2010). A spatio-temporal downscaler for output from numerical models. *Annals of Applied Statistics*, 4(4), 1820-1848.
7. McMillan, N. J., Holland, D. M., Morara, M., & Feng, J. (2010). Combining numerical model output and particulate data using Bayesian space-time modeling. *Environmetrics*, 21(1), 48-63.
8. Fuentes, M., & Raftery, A. E. (2005). Model Evaluation and Spatial Interpolation by Bayesian Combination of Observations with Outputs from Numerical Models. *Biometrics*, 61(1), 36-45.
9. Akita, Y., Chen, J.-C., & Serre, M. L. (2012). The moving-window Bayesian maximum entropy framework: estimation of PM_{2.5} yearly average concentration across the con-

tiguous United States. *Journal of Exposure Science and Environmental Epidemiology*, 22(5), 496-501.

10. Reyes, J. M., & Serre, M. L. (2014). An LUR/BME Framework to Estimate $PM_{2.5}$ Explained by on Road Mobile and Stationary Sources. *Environmental Science & Technology*, 48(3), 1736-1744.