

SVCD 空间变系数降尺度融合方法数学原理

基于 Berrocal et al. (2010) 空间变系数模型 + REML 优化

2026-06-04

目录

1	概述	3
2	数据变换	3
2.1	前向 Log 变换	3
2.2	U 的标准化	3
2.3	反变换	3
3	空间变系数模型	4
3.1	模型定义	4
3.2	高斯过程先验	4
3.3	设计矩阵形式	4
4	Matérn 协方差核	5
4.1	一般形式	5
4.2	特殊情况	5
4.3	待估超参数	5
5	边际协方差矩阵	6
5.1	推导	6
5.2	物理解释	6
6	REML 参数估计	7
6.1	REML 负对数似然	7
6.2	GLS 估计固定效应	7
6.3	数值计算 (Cholesky 分解)	7
6.4	优化方法	7
6.5	初始参数选择	7
7	空间预测	8
7.1	交叉协方差	8
7.2	Kriging 预测均值	8

7.3	预测方差	8
7.4	最终预测	8
7.5	Delta Method 标准差	9
8	完整算法伪代码	10
9	与其他方法的对比	11
9.1	优势	11
9.2	局限性	11
10	超参数默认值	12

1 概述

SVCD (Spatially Varying Coefficient Downscaler) 是一种现代化的空间数据融合方法, 将粗分辨率化学传输模型 (CMAQ) 输出与稀疏的地面监测站点观测数据进行融合, 生成高分辨率的 PM_{2.5}/O₃ 浓度估计。

该方法是对经典 Downscaler (McMillan et al., 2010) 的改进, 核心改进包括:

1. **Log 变换:** 将浓度值变换到对数尺度, 使其分布更接近高斯假设, 并减弱右偏与异方差
2. **空间变系数:** 截距和斜率均为空间高斯过程, 允许不同区域有不同的 obs-CMAQ 关系
3. **Matérn 核:** 采用 Matérn 协方差家族 (固定 $\nu = 1.5$), 比单一指数核提供更现代且常用的空间相关结构
4. **REML 优化:** 替代 MCMC, 计算效率大幅提升
5. **偏差修正反变换:** Log 变换反变换时的 Jensen 不等式修正

2 数据变换

2.1 前向 Log 变换

设 $Y(\mathbf{s}_i)$ 为监测站点 $\mathbf{s}_i$ 处的观测浓度 ($i = 1, \dots, n$), $X(\mathbf{s}_i)$ 为对应位置的 CMAQ 模型模拟值。

定义 Log 变换:

$$\boxed{Z(\mathbf{s}) = \log(Y(\mathbf{s}) + c), \quad U(\mathbf{s}) = \log(X(\mathbf{s}) + c)} \quad (1)$$

其中 $c = 1.0$ 为常数, 确保 log 变换有意义 (避免负值或零值问题)。

2.2 U 的标准化

为提高数值稳定性, 对 U 进行标准化:

$$\boxed{\tilde{U}(\mathbf{s}) = \frac{U(\mathbf{s}) - \mu_U}{\sigma_U}} \quad (2)$$

其中 $\mu_U = \frac{1}{n} \sum_{i=1}^n U(\mathbf{s}_i)$, $\sigma_U = \text{std}(U(\mathbf{s}_1), \dots, U(\mathbf{s}_n))$ 。

2.3 反变换

预测完成后, 从 Log 尺度回到原始浓度尺度。

简单反变换 (无偏差修正):

$$\hat{Y}(\mathbf{s}_0) = \exp(\hat{\mu}(\mathbf{s}_0)) - c \quad (3)$$

偏差修正反变换 (推荐):

$$\hat{Y}(\mathbf{s}_0) = \exp\left(\hat{\mu}(\mathbf{s}_0) + \frac{1}{2}\hat{\sigma}^2(\mathbf{s}_0)\right) - c \quad (4)$$

其中 $\hat{\mu}(\mathbf{s}_0)$ 为 Log 尺度的预测均值, $\hat{\sigma}^2(\mathbf{s}_0)$ 为 Log 尺度的预测方差。该修正基于对数正态分布的性质: 若 $\ln W \sim \mathcal{N}(\mu, \sigma^2)$, 则 $\mathbb{E}[W] = \exp(\mu + \sigma^2/2)$ 。

最终截断为非负值: $\hat{Y}(\mathbf{s}_0) = \max(0, \hat{Y}(\mathbf{s}_0))$ 。

3 空间变系数模型

3.1 模型定义

在 Log 尺度下, SVCD 的观测模型为:

$$Z(\mathbf{s}) = \beta_0 + \beta_1 \tilde{U}(\mathbf{s}) + w_0(\mathbf{s}) + w_1(\mathbf{s}) \tilde{U}(\mathbf{s}) + \varepsilon(\mathbf{s}) \quad (5)$$

其中:

- β_0 : 全局截距 (固定效应)
- β_1 : 全局斜率 (固定效应), 反映 CMAQ 与观测的总体线性关系
- $w_0(\mathbf{s})$: 空间变截距 (随机效应), 捕捉 CMAQ 在不同地区的系统偏差
- $w_1(\mathbf{s})$: 空间变斜率 (随机效应), 捕捉不同地区 CMAQ 与观测关系的差异
- $\varepsilon(\mathbf{s}) \sim \mathcal{N}(0, \tau^2)$: 独立观测噪声 (nugget effect)

3.2 高斯过程先验

空间变系数的先验为独立的零均值高斯过程:

$$w_0(\mathbf{s}) \sim \mathcal{GP}(0, \sigma_0^2 \cdot K_0(\mathbf{s}, \mathbf{s}')) \quad (6)$$

$$w_1(\mathbf{s}) \sim \mathcal{GP}(0, \sigma_1^2 \cdot K_1(\mathbf{s}, \mathbf{s}')) \quad (7)$$

其中 K_0 和 K_1 为 Matérn 协方差核 (见第 4 节)。

实现说明: 在参数估计和预测中, $w_0(\mathbf{s})$ 和 $w_1(\mathbf{s})$ 通过边际化被隐式建模 (即积分掉随机效应, 直接在边际协方差 $\mathbf{V}$ 上做似然优化和 Kriging 预测), 代码中不显式恢复这两个空间场。若需要可视化局部系数场, 可通过条件高斯过程后验 $\mathbb{E}[w_k | \mathbf{z}]$ 计算。

3.3 设计矩阵形式

定义设计矩阵 $\mathbf{X}$ 和响应向量 $\mathbf{z}$:

$$\mathbf{X} = \begin{pmatrix} 1 & \tilde{U}(\mathbf{s}_1) \\ 1 & \tilde{U}(\mathbf{s}_2) \\ \vdots & \vdots \\ 1 & \tilde{U}(\mathbf{s}_n) \end{pmatrix}, \quad \mathbf{z} = \begin{pmatrix} Z(\mathbf{s}_1) \\ Z(\mathbf{s}_2) \\ \vdots \\ Z(\mathbf{s}_n) \end{pmatrix} \quad (8)$$

模型可紧凑地写为:

$$\mathbf{z} = \mathbf{X}\boldsymbol{\beta} + \mathbf{w}(\mathbf{s}) + \boldsymbol{\varepsilon} \quad (9)$$

其中 $\boldsymbol{\beta} = (\beta_0, \beta_1)^\top$ 。

4 Matérn 协方差核

4.1 一般形式

Matérn 协方差核的参数化形式为:

$$K(d; \sigma^2, \rho, \nu) = \sigma^2 \cdot M_\nu \left(\frac{d}{\rho} \right) \quad (10)$$

其中 $d = \|\mathbf{s} - \mathbf{s}'\|$ 为欧氏距离, σ^2 为方差参数, $\rho > 0$ 为空间范围参数 (range), ν 为平滑度参数。

4.2 特殊情况

SVCD 实现支持三种 ν 值。**注意:** ν_0 和 ν_1 为用户指定的固定值 (默认均为 1.5), **不参与 REML 优化**。实际优化的超参数仅有 5 个 ($\sigma_0, \rho_0, \sigma_1, \rho_1, \tau$)。选择固定 ν 是因为 Matérn 平滑度在有限样本下通常难以与 range 参数区分 (confounded), 固定 $\nu = 1.5$ 对应一阶均方可微的空间场, 是地球科学中的标准选择。

$$M_\nu(r) = \begin{cases} \exp(-r) & \nu = 0.5 \quad (\text{指数核}) \\ (1 + \sqrt{3}r) \cdot \exp(-\sqrt{3}r) & \nu = 1.5 \quad (\text{默认}) \\ (1 + \sqrt{5}r + \frac{5}{3}r^2) \cdot \exp(-\sqrt{5}r) & \nu = 2.5 \end{cases} \quad (11)$$

其中 $r = d/\rho$ 。

4.3 待估超参数

SVCD 模型共有 5 个待估超参数 (均在 log 空间优化), 平滑度 ν_0, ν_1 为固定输入:

表 1: SVCD 超参数

参数	符号	说明
σ_0	log_sigma0	截距场 $w_0(s)$ 的标准差
ρ_0	log_rho0	截距场的空间范围（距离单位）
σ_1	log_sigma1	斜率场 $w_1(s)$ 的标准差
ρ_1	log_rho1	斜率场的空间范围（距离单位）
τ	log_tau	观测噪声标准差

5 边际协方差矩阵

5.1 推导

将随机效应边际化，得到 $\mathbf{z}$ 的边际分布：

$$\mathbf{z} \mid \boldsymbol{\beta}, \boldsymbol{\theta} \sim \mathcal{N}(\mathbf{X}\boldsymbol{\beta}, \mathbf{V}) \quad (12)$$

其中边际协方差矩阵 $\mathbf{V}$ 为：

$$\mathbf{V} = \boldsymbol{\Sigma}_0 + (\tilde{\mathbf{u}}\tilde{\mathbf{u}}^\top) \odot \boldsymbol{\Sigma}_1 + (\tau^2 + \delta)\mathbf{I}_n \quad (13)$$

其中：

- $\boldsymbol{\Sigma}_0 = \sigma_0^2 \cdot [M_{\nu_0}(d_{ij}/\rho_0)]_{n \times n}$ ：截距场协方差矩阵
- $\boldsymbol{\Sigma}_1 = \sigma_1^2 \cdot [M_{\nu_1}(d_{ij}/\rho_1)]_{n \times n}$ ：斜率场协方差矩阵
- $\tilde{\mathbf{u}}\tilde{\mathbf{u}}^\top$ ：标准化 CMAQ 值的外积矩阵
- $\odot$ ：Hadamard 逐元素积
- $\delta = 10^{-6}$ ：数值稳定性 jitter

5.2 物理解释

$\mathbf{V}$ 的三项分别对应：

1. $\boldsymbol{\Sigma}_0$ ：空间变截距引入的观测间相关性
2. $(\tilde{\mathbf{u}}\tilde{\mathbf{u}}^\top) \odot \boldsymbol{\Sigma}_1$ ：空间变斜率引入的观测间相关性（与 CMAQ 值成比例）
3. $\tau^2\mathbf{I}_n$ ：独立观测噪声

Hadamard 积的含义： $[V]_{ij}$ 中的 $\tilde{U}(\mathbf{s}_i) \cdot \tilde{U}(\mathbf{s}_j)$ 项表示当两个站点的 CMAQ 值都较大时，它们通过斜率场的耦合更强。

6 REML 参数估计

6.1 REML 负对数似然

限制最大似然 (Restricted Maximum Likelihood, REML) 消除了固定效应 β 对方差参数估计的影响。REML 负对数似然为:

$$\ell_{\text{REML}}(\theta) = \frac{1}{2} \left[\ln |\mathbf{V}| + (\mathbf{z} - \mathbf{X}\hat{\beta})^\top \mathbf{V}^{-1} (\mathbf{z} - \mathbf{X}\hat{\beta}) + \ln |\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X}| \right] \quad (14)$$

其中 $\theta = (\log \sigma_0, \log \rho_0, \log \sigma_1, \log \rho_1, \log \tau)$ 为待优化的超参数向量。上式省略了与参数无关的常数项 (up to an additive constant)。

6.2 GLS 估计固定效应

在给定 θ 下, 固定效应的广义最小二乘 (GLS) 估计为:

$$\hat{\beta} = \left(\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X} \right)^{-1} \mathbf{X}^\top \mathbf{V}^{-1} \mathbf{z} \quad (15)$$

6.3 数值计算 (Cholesky 分解)

为高效求解, 使用 Cholesky 分解 $\mathbf{V} = \mathbf{L}\mathbf{L}^\top$:

1. $\ln |\mathbf{V}| = 2 \sum_{i=1}^n \ln L_{ii}$ (对角元素对数之和的两倍)
2. $\mathbf{V}^{-1}\mathbf{X}$ 通过 $\mathbf{L}^\top \backslash (\mathbf{L} \backslash \mathbf{X})$ 计算 (前向 + 回代)
3. $\mathbf{V}^{-1}\mathbf{z}$ 同理

6.4 优化方法

使用 L-BFGS-B 优化器最小化 ℓ_{REML} , 参数约束为:

$$-6 \leq \theta_i \leq 6, \quad i = 1, \dots, 5 \quad (16)$$

这对应原始参数范围 $e^{-6} \approx 0.0025$ 到 $e^6 \approx 403$ 。

6.5 初始参数选择

初始超参数基于数据自适应设定:

$$\sigma_0^{(0)} = 0.5 \cdot \text{sd}(\mathbf{z}) \quad (17)$$

$$\rho_0^{(0)} = \text{median}(d_{ij}) \quad (18)$$

$$\sigma_1^{(0)} = 0.2 \cdot \text{sd}(\mathbf{z}) \quad (19)$$

$$\rho_1^{(0)} = \text{median}(d_{ij}) \quad (20)$$

$$\tau^{(0)} = 0.3 \cdot \text{sd}(\mathbf{z}) \quad (21)$$

其中 d_{ij} 为训练站点间的距离矩阵中的正元素。

7 空间预测

7.1 交叉协方差

给定新预测点 $\mathbf{s}_0$ (对应标准化 CMAQ 值 $\tilde{U}(\mathbf{s}_0)$)，训练点与预测点之间的交叉协方差向量为：

$$\mathbf{c}(\mathbf{s}_0) = \mathbf{c}_0(\mathbf{s}_0) + \tilde{U}(\mathbf{s}_0) \cdot (\tilde{\mathbf{u}} \odot \mathbf{c}_1(\mathbf{s}_0)) \quad (22)$$

其中：

$$c_{0,i}(\mathbf{s}_0) = \sigma_0^2 \cdot M_{\nu_0} \left(\frac{\|\mathbf{s}_i - \mathbf{s}_0\|}{\rho_0} \right) \quad (23)$$

$$c_{1,i}(\mathbf{s}_0) = \sigma_1^2 \cdot M_{\nu_1} \left(\frac{\|\mathbf{s}_i - \mathbf{s}_0\|}{\rho_1} \right) \quad (24)$$

即 $[\mathbf{c}]_i = c_{0,i} + \tilde{U}(\mathbf{s}_i) \cdot \tilde{U}(\mathbf{s}_0) \cdot c_{1,i}$ 。

7.2 Kriging 预测均值

Log 尺度的最优线性无偏预测 (BLUP) 为：

$$\hat{\mu}(\mathbf{s}_0) = \mathbf{x}_0^\top \hat{\boldsymbol{\beta}} + \mathbf{c}(\mathbf{s}_0)^\top \mathbf{V}^{-1}(\mathbf{z} - \mathbf{X}\hat{\boldsymbol{\beta}}) \quad (25)$$

其中 $\mathbf{x}_0 = (1, \tilde{U}(\mathbf{s}_0))^\top$ 为预测点的设计向量。

7.3 预测方差

Log 尺度的预测方差 (含固定效应不确定性修正)。注：此处 v_{prior} 包含 nugget 项 τ^2 ，对应的预测目标是新位置处的观测值 (含测量噪声)，而非潜在平滑过程的均值面。若目标为潜在过程预测，应去掉 τ^2 项。

$$\hat{\sigma}^2(\mathbf{s}_0) = \underbrace{v_{\text{prior}}(\mathbf{s}_0)}_{\text{先验方差}} - \underbrace{\mathbf{c}(\mathbf{s}_0)^\top \mathbf{V}^{-1} \mathbf{c}(\mathbf{s}_0)}_{\text{Kriging 方差缩减}} + \underbrace{\boldsymbol{\delta}^\top (\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1} \boldsymbol{\delta}}_{\text{固定效应不确定性}} \quad (26)$$

其中：

$$v_{\text{prior}}(\mathbf{s}_0) = \sigma_0^2 + \tilde{U}(\mathbf{s}_0)^2 \cdot \sigma_1^2 + \tau^2 \quad (27)$$

$$\boldsymbol{\delta} = \mathbf{x}_0 - \mathbf{X}^\top \mathbf{V}^{-1} \mathbf{c}(\mathbf{s}_0) \quad (28)$$

7.4 最终预测

将 Log 尺度预测回到原始尺度：

$$\hat{Y}(\mathbf{s}_0) = \max \left(0, \exp \left(\hat{\mu}(\mathbf{s}_0) + \frac{1}{2} \hat{\sigma}^2(\mathbf{s}_0) \right) - c \right) \quad (29)$$

若不使用偏差修正 (`bias_correction=False`), 则:

$$\hat{Y}(\mathbf{s}_0) = \max(0, \exp(\hat{\mu}(\mathbf{s}_0)) - c) \quad (30)$$

7.5 Delta Method 标准差

基于一阶 Delta method 近似的原始尺度预测标准差:

$$\boxed{\text{SE}_{\text{pred}}(\mathbf{s}_0) \approx \exp(\hat{\mu}(\mathbf{s}_0)) \cdot \sqrt{\hat{\sigma}^2(\mathbf{s}_0)}} \quad (31)$$

注:这是一阶近似。若 $Z \sim \mathcal{N}(\mu, \sigma^2)$, 则 $W = \exp(Z) - c$ 的精确标准差为 $\sqrt{(e^{\sigma^2} - 1) \cdot e^{2\mu + \sigma^2}}$ 。当 σ^2 较小时 (< 0.5), Delta method 与精确公式非常接近。

8 完整算法伪代码

Algorithm 1 SVCD 融合算法

Require: 监测站坐标 $\mathbf{S}$, 观测值 $\mathbf{y}$, CMAQ 值 $\mathbf{x}$; 预测点坐标 $\mathbf{S}_{\text{new}}$, 预测点 CMAQ 值 $\mathbf{x}_{\text{new}}$

Ensure: 预测浓度 $\hat{\mathbf{Y}}$

```

1: Phase 1: 数据变换
2:  $\mathbf{z} \leftarrow \log(\mathbf{y} + c)$  {Log 变换观测值}
3:  $\mathbf{u} \leftarrow \log(\mathbf{x} + c)$  {Log 变换 CMAQ 值}
4:  $\tilde{\mathbf{u}} \leftarrow (\mathbf{u} - \mu_U)/\sigma_U$  {标准化}
5:  $\mathbf{X} \leftarrow [\mathbf{1}, \tilde{\mathbf{u}}]$  {设计矩阵}
6:  $\mathbf{D} \leftarrow \text{cdist}(\mathbf{S}, \mathbf{S})$  {距离矩阵}
7:
8: Phase 2: REML 优化
9:  $\boldsymbol{\theta}_0 \leftarrow$  数据自适应初始化 (式 17-21)
10: for L-BFGS-B 迭代  $m = 1, \dots, N_{\text{max}}$  do
11:    $\mathbf{V} \leftarrow \boldsymbol{\Sigma}_0 + (\tilde{\mathbf{u}}\tilde{\mathbf{u}}^\top) \odot \boldsymbol{\Sigma}_1 + \tau^2 \mathbf{I}$  {式 13}
12:    $\mathbf{L} \leftarrow \text{Cholesky}(\mathbf{V})$ 
13:    $\hat{\boldsymbol{\beta}} \leftarrow (\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{V}^{-1} \mathbf{z}$  {式 15}
14:    $\ell(\boldsymbol{\theta}) \leftarrow \text{REML NLL}$  (式 14)
15:   更新  $\boldsymbol{\theta}$ 
16: end for
17: 存储  $\hat{\boldsymbol{\beta}}, \hat{\boldsymbol{\theta}}, \mathbf{V}^{-1}(\mathbf{z} - \mathbf{X}\hat{\boldsymbol{\beta}})$ 
18:
19: Phase 3: 空间预测
20: for 每个预测点  $\mathbf{s}_0 \in \mathbf{S}_{\text{new}}$  do
21:    $\tilde{U}(\mathbf{s}_0) \leftarrow (\log(x_0 + c) - \mu_U)/\sigma_U$ 
22:    $\mathbf{c}(\mathbf{s}_0) \leftarrow$  交叉协方差 (式 22)
23:    $\hat{\mu}(\mathbf{s}_0) \leftarrow \mathbf{x}_0^\top \hat{\boldsymbol{\beta}} + \mathbf{c}(\mathbf{s}_0)^\top \mathbf{V}^{-1} \mathbf{r}$  {式 25}
24:    $\hat{\sigma}^2(\mathbf{s}_0) \leftarrow$  预测方差 (式 26)
25:    $\hat{Y}(\mathbf{s}_0) \leftarrow \max(0, e^{\hat{\mu} + \hat{\sigma}^2/2} - c)$  {式 29}
26: end for

```

9 与其他方法的对比

表 2: SVCD 与 Downscaler、aVNA 的对比

特征	SVCD	Downscaler	aVNA
回归模型	空间变系数	全局系数（基线实现）	无回归
空间核	Matérn ($\nu=1.5$)	指数核	IDW
参数估计	REML (L-BFGS-B)	MCMC (2500 迭代)	无参数
数据变换	Log + 偏差修正	无变换	无变换
不确定性	解析方差	后验样本	无
训练复杂度	$O(N_{\text{iter}} \cdot n^3)$	$O(N_{\text{MCMC}} \cdot n^3)$	$O(n \log n)$
单日耗时	~20s (645 站)	~5min	~0.8s
精度 (R^2)	~0.74	~0.73	~0.71

9.1 优势

1. **空间变系数**: 允许不同区域有不同的 obs-CMAQ 关系，比全局线性更灵活
2. **REML 替代 MCMC**: 计算快 $10\times+$ ，且无 burn-in/thinning/收敛诊断问题
3. **Log 变换**: 浓度数据天然右偏，Log 变换使分布更接近正态
4. **偏差修正**: 解决 Log 反变换的 Jensen 不等式偏差
5. **Matérn 协方差**: Matérn 家族比指数核更灵活；本实现固定 $\nu = 1.5$ ，获得稳健且常用的空间相关结构
6. **解析不确定性**: 直接给出预测方差，无需 Monte Carlo

9.2 局限性

1. **计算瓶颈**: $O(n^3)$ Cholesky 分解， $n > 2000$ 时变慢
2. **全域矩阵**: 未使用稀疏近似（如低秩、Vecchia），内存占用 $O(n^2)$
3. **线性均值**: 固定效应仍为线性，非线性关系需进一步扩展
4. **空间平稳性**: Matérn 核假设各向同性平稳
5. **仅空间维**: 每日独立拟合，不利用时间信息

10 超参数默认值

表 3: SVCD 超参数默认值

参数	默认值	说明
c	1.0	Log 变换常数
ν_0	1.5	截距场 Matérn 平滑度
ν_1	1.5	斜率场 Matérn 平滑度
δ (jitter)	10^{-6}	数值稳定性噪声
standardize_u	True	是否标准化 CMAQ Log 值
bias_correction	True	反变换偏差修正
$N_{\max}$ (maxiter)	150	L-BFGS-B 最大迭代
ftol	10^{-6}	函数值收敛阈值
gtol	10^{-5}	梯度收敛阈值
bounds	$[-6, 6]^5$	参数空间约束 (log 尺度)

参考文献

1. Berrocal, V. J., Gelfand, A. E., & Holland, D. M. (2010). A spatio-temporal downscaler for output from numerical models. *Annals of Applied Statistics*, 4(4), 1820-1848.
2. McMillan, N. J., Holland, D. M., Morara, M., & Feng, J. (2010). Combining numerical model output and particulate data using Bayesian space-time modeling. *Environmetrics*, 21(1), 48-63.
3. Friberg, M. D., et al. (2016). Method for fusing observational data and chemical transport model simulations to estimate spatiotemporally resolved ambient air pollution. *Environmental Science & Technology*, 50(7), 3695-3705.
4. Rasmussen, C. E., & Williams, C. K. I. (2006). *Gaussian Processes for Machine Learning*. MIT Press.
5. Stein, M. L. (1999). *Interpolation of Spatial Data: Some Theory for Kriging*. Springer.